Karpenko Bohdan AIS ID: 135007

Dátové štruktúry a algoritmy

Implementácia a testovanie efektívnosti algoritmov: hašovacia tabuľka s otvoreným adresovaním, červeno-čierny strom, 2-3 strom

Karpenko Bohdan AIS ID: 135007

Princíp testovania

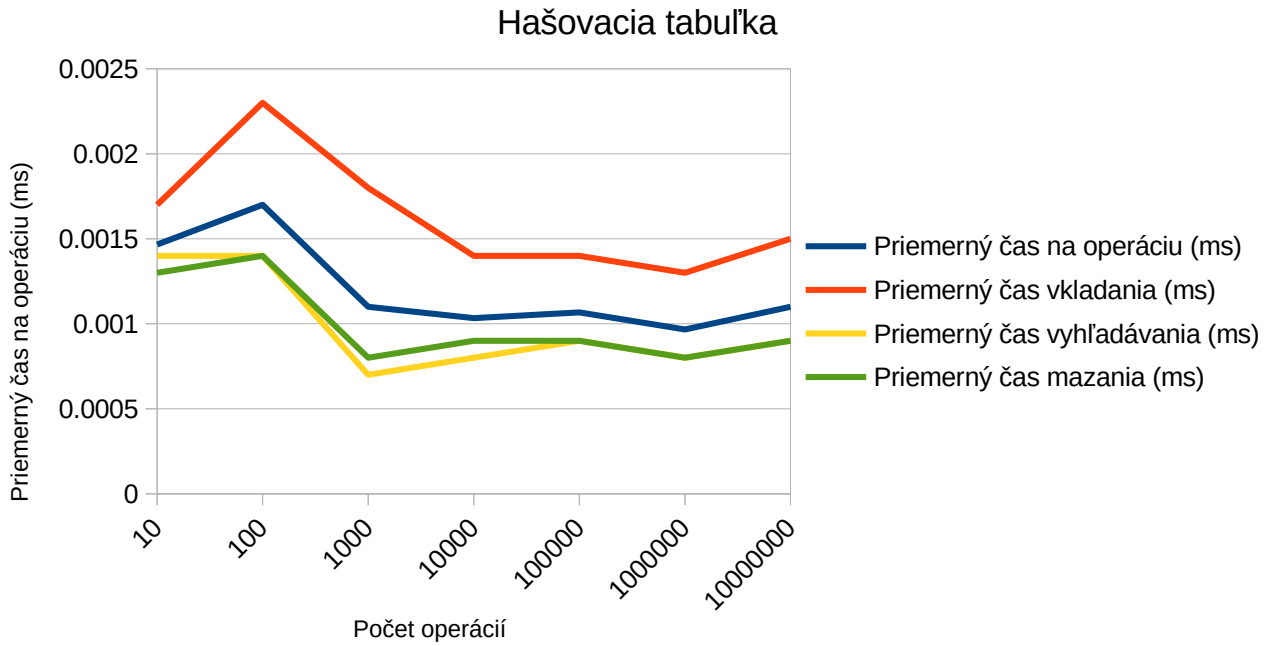
Testovanie prebiehalo na sekvencii údajov, ktorá pozostávala z: n operácií vkladania, n operácií vyhľadávania a n operácií mazania, kde n predstavuje počet operácií uvedený v nasledujúcich tabuľkách a grafoch.
Pre testovanie boli použité hodnoty n: 10, 100, 1000, 10 000, 100 000, 1 000 000, 10 000 000.
Počas testovania sa zaznamenával čas vykonania každej operácie (vkladanie, vyhľadávanie a mazanie) a maximálne množstvo pamäte použitej implementáciou algoritmu.

Karpenko Bohdan AIS ID: 135007

Výsledky testovania výkonnosti algoritmov.

1. Hašovacia tabuľka

Počet operácií	Priemerný čas na operáciu (ms)	Priemerný čas vkladania (ms)	Priemerný čas vyhľadávania (ms)	Priemerný čas mazania (ms)
10	0.00047	0.0017	0.0014	0.0013
100	0.00047	0.0023	0.0014	0.0014
1000	0.00023	0.0018	0.0007	0.0008
10000	0.00027	0.0014	0.0008	0.0009
100000	0.00030	0.0014	0.0009	0.0009
1000000	0.00027	0.0013	0.0008	0.0008
10000000	0.00030	0.0015	0.0009	0.0009



Ako je vidieť z grafu, od hodnoty 1000 prvkov sa rýchlosť vykonávania operácií stabilizuje. Je to spôsobené tým, že veľkosť tabuľky sa zväčšuje podľa pravidla:

```
newSize = oldSize * 2;
```

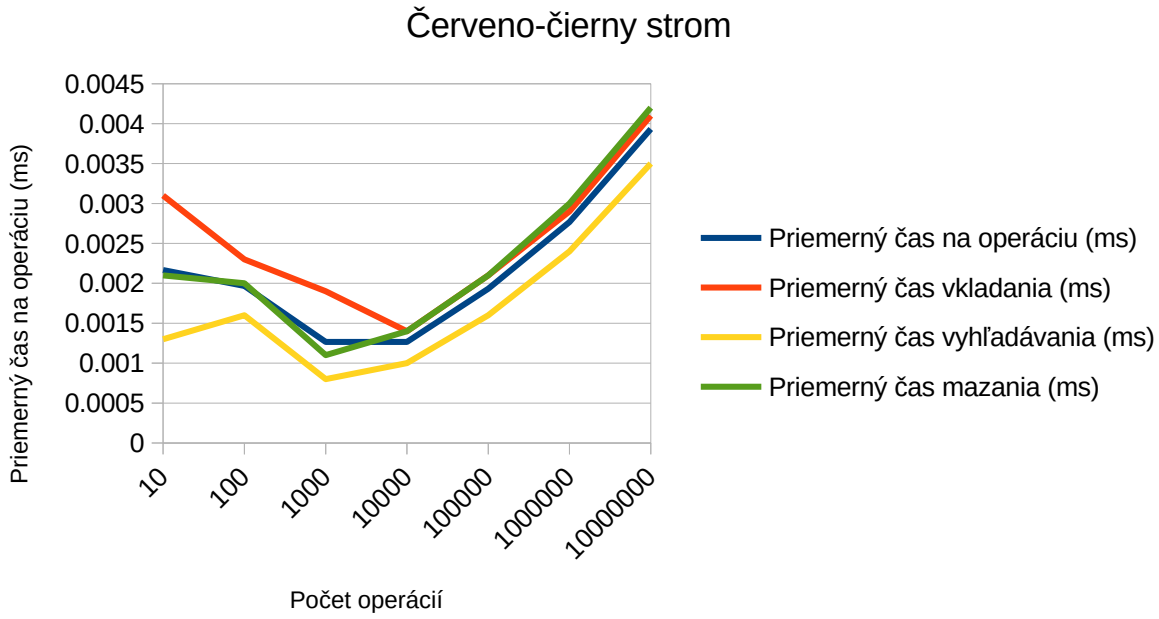
čo vedie k častému rozširovaniu tabuľky na začiatku jej zapĺňania. Postupom času však počet týchto rozšírení pri vkladaní klesá, čo zodpovedá konštantnej časovej zložitosti operácií. Takéto počiatočné výkyvy v meraniach sa pozorujú aj pri iných dátových štruktúrach, a preto môžu byť čiastočne spôsobené aj chybou merania.

Toto pravidlo zároveň vysvetľuje vyšší čas vykonania operácií pozorovaný na začiatku testovania. O niečo vyšší priemerný čas vkladania je spôsobený tým, že táto operácia

zahŕňa aj možnú zmenu veľkosti tabuľky, čo ju robí mierne pomalšou v porovnaní s operáciami vyhľadávania a mazania.

2. Červeno-čierny strom

Počet operácií	Priemerný čas na operáciu (ms)	Priemerný čas vkladania (ms)	Priemerný čas vyhľadávania (ms)	Priemerný čas mazania (ms)
10	0.00217	0.0031	0.0013	0.0021
100	0.00197	0.0023	0.0016	0.002
1000	0.00127	0.0019	0.0008	0.0011
10000	0.00127	0.0014	0.001	0.0014
100000	0.00193	0.0021	0.0016	0.0021
1000000	0.00277	0.0029	0.0024	0.003
10000000	0.00393	0.0041	0.0035	0.0042



Ako je vidieť z grafu, pri malých objemoch údajov (do 100 prvkov) sa vyskytujú výrazné výkyvy v priemernom čase vykonávania operácií. Je to spôsobené nielen efektmi vyrovnávacej pamäte procesora, ale aj chybami merania, ktoré vznikajú v dôsledku správania operačného systému, plánovača vlákien a ďalších systémových procesov. Tieto faktory majú väčší vplyv pri malom počte iterácií.

Od približne 10 000 operácií sa čas vykonania stabilizuje a vykazuje postupný nárast. To je v súlade s teoretickou logaritmickou časovou zložitosťou červeno-čierneho stromu

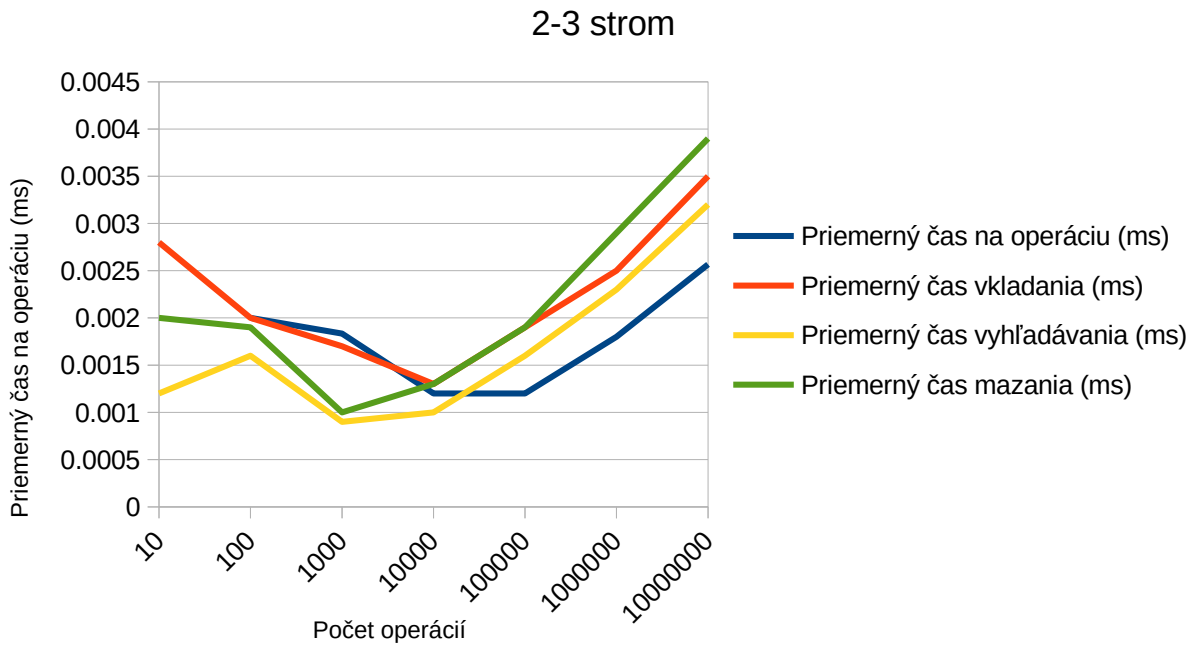
O(log n), pretože so zvyšujúcim sa počtom prvkov sa štruktúra stromu komplikuje a zvyšuje sa počet potrebných rotácií a zmien farieb na zachovanie jeho vyváženosti.

Najviac času si vyžadujú operácie vkladania a mazania, čo je spôsobené potrebou vyvážiť strom po každej takejto operácii. Tieto operácie vyžadujú dodatočné zmeny v štruktúre uzlov, aby sa zachovali vlastnosti červeno-čierneho stromu. Naopak, operácia vyhľadávania je najrýchlejšia, keďže nemení štruktúru stromu a len prechádza už usporiadané uzly.

Výsledky teda potvrdzujú očakávané logaritmické správanie červeno-čierneho stromu pri rastúcom objeme údajov a zároveň poukazujú na relatívnu stabilitu a efektivitu operácie vyhľadávania v porovnaní s ostatnými.

3. 2-3 strom

Počet operácií	Priemerný čas na operáciu (ms)	Priemerný čas vkladania (ms)	Priemerný čas vyhľadávania (ms)	Priemerný čas mazania (ms)
10	0.00200	0.0028	0.0012	0.0020
100	0.00183	0.0020	0.0016	0.0019
1000	0.00120	0.0017	0.0009	0.0010
10000	0.00120	0.0013	0.0010	0.0013
100000	0.00180	0.0019	0.0016	0.0019
1000000	0.00257	0.0025	0.0023	0.0029
10000000	0.00353	0.0035	0.0032	0.0039



V počiatočných fázach (do 100 prvkov) vykazuje priemerný čas vykonávania operácií v 2-3 strome výrazné výkyvy. Toto správanie je spôsobené nielen efektmi cache, keď sa celá štruktúra zmestí do vyrovnávacej pamäte procesora, ale aj meracími odchýlkami, ktoré sú typické pri malom počte operácií. Takéto odchýlky vznikajú v dôsledku systémovej aktivity operačného systému, plánovania vlákien a ďalších externých faktorov, ktoré majú neúmerne veľký vplyv pri nízkom počte iterácií.

Po 1 000–10 000 operáciách sa čas vykonania stabilizuje a následne postupne narastá. To súvisí s logaritmickou zložitosťou základných operácií v 2-3 strome, ktorý udržiava vyváženosť prostredníctvom rozdeľovania alebo spájania uzlov. So zvyšujúcim sa množstvom údajov sa tieto pomocné operácie vyskytujú častejšie, čo spôsobuje nárast času.

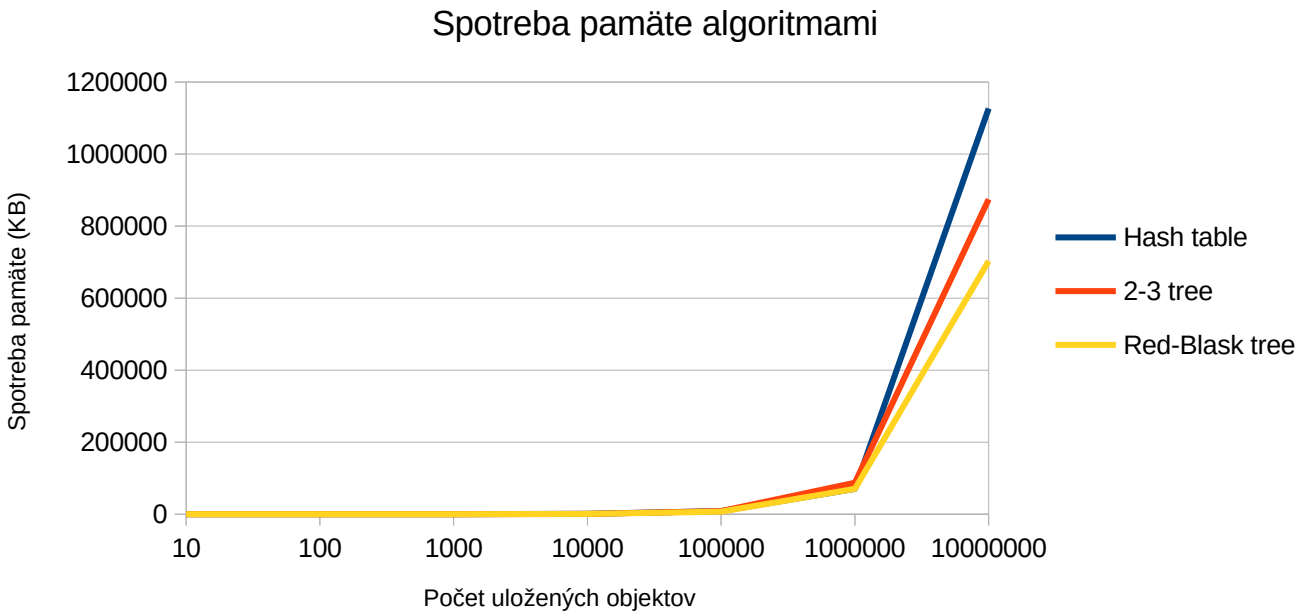
Ako je vidieť z grafu, najviac času si vyžadujú operácie vkladania a mazania, pretože zahŕňajú dodatočné úpravy štruktúry stromu na zachovanie jeho vyváženosti. Najmä operácia mazania si vyžaduje nielen vyhľadanie uzla, ale aj potenciálne spájanie alebo presun kľúčov medzi uzlami, čo ju robí výpočtovo náročnou. Naopak, operácia vyhľadávania je najrýchlejšia, keďže je najpriamejšia — nemení štruktúru stromu a prechádza len po usporiadaných uzloch.

Celkovo získané výsledky potvrdzujú očakávanú asymptotickú zložitosť vykonávania operácií v 2-3 strome a preukazujú jeho efektivitu pri práci s veľkými objemami údajov.

Karpenko Bohdan AIS ID: 135007

Porovnanie spotreby pamäte algoritmami

Počet vložení	Spotreba pamäte hašovacej tabuľky (KB)	Spotreba pamäte 2-3 stromu (KB)	Spotreba pamäte červeno-čierneho stromu (KB)
10	2	0	0
100	8	7	7
1000	68	88	70
10000	1100	875	703
100000	8800	8741	7031
1000000	70400	87419	70312
10000000	1126400	874447	703125



Na základe prezentovaných údajov algoritmy vykazujú rozdielnu efektivitu vo využívaní operačnej pamäte pri narastajúcom počte vložení. Najväčšia spotreba pamäte sa pozoruje pri hašovacej tabuľke. Je to spôsobené jej štruktúrnou vlastnosťou — aby sa zabezpečil konštantný čas prístupu, hašovacia tabuľka si obvykle udržiava rezervný počet buniek, ktorý presahuje počet skutočne uložených prvkov. Časť tejto pamäte ostáva nevyužitá, aby sa minimalizovali kolízie a zabezpečil rýchly prístup pri vkladaní a vyhľadávaní. Z tohto dôvodu zaberá hašovacia tabuľka viac pamäte než stromové štruktúry, aj pri rovnakom počte dát.

Pokiaľ ide o stromové štruktúry, 2-3 strom sa ukázal ako menej efektívny z hľadiska spotreby pamäte v porovnaní s červeno-čiernym stromom. Je to spôsobené

implementačnými špecifikami: každý uzol 2-3 stromu obsahuje dve plnohodnotné dátové bunky, a nie len ukazovatele na ne. Tento prístup bol zvolený za účelom optimalizácie — zníženie počtu volaní funkcie `malloc()` a tým aj systémových požiadaviek umožňuje zvýšiť celkovú rýchlosť operácií nad stromom, najmä pri veľkých objemoch vkladaných údajov.

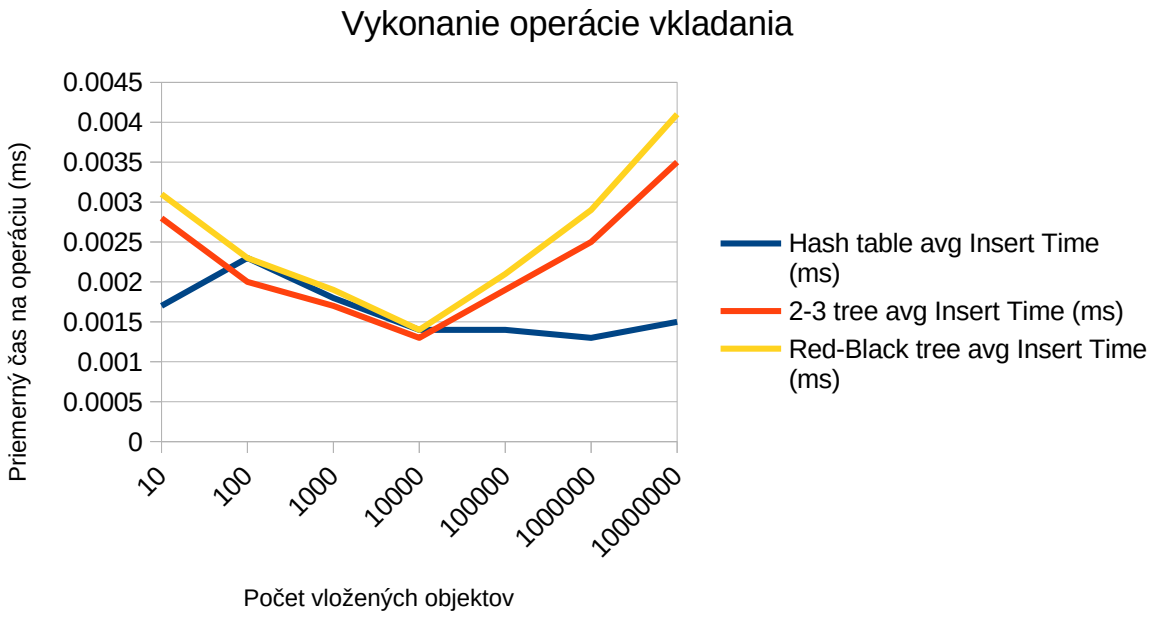
Naopak, červeno-čierny strom ukladá len jednu dátovú bunku na uzol, čo z neho robí najúspornejšiu štruktúru z hľadiska pamäťovej náročnosti spomedzi všetkých testovaných riešení. Napriek tomu, že každý uzol obsahuje aj informáciu o farbe a odkaz na nadradený uzol, implementácia ostáva kompaktná a efektívna z pohľadu využitia pamäte.

Karpenko Bohdan AIS ID: 135007

Porovnanie rýchlosti vykonania jednotlivých operácií medzi algoritmami

1. Porovnanie rýchlosti vykonania operácie vkladania.

Počet vložení	Priemerný čas vkladania – hašovacia tabuľka (ms)	Priemerný čas vkladania – 2-3 strom (ms)	Priemerný čas vkladania – červeno-čierny strom (ms)
10	0.0017	0.0028	0.0031
100	0.0023	0.0020	0.0023
1000	0.0018	0.0017	0.0019
10000	0.0014	0.0013	0.0014
100000	0.0014	0.0019	0.0021
1000000	0.0013	0.0025	0.0029
10000000	0.0015	0.0035	0.0041



Z grafu a tabuľky je zrejmé, že najnižší priemerný čas vkladania vykazuje hašovacia tabuľka. Je to dané jej štruktúrnou vlastnosťou – tabuľka má vopred rezervovaný dostatočný počet voľných buniek, čo umožňuje vyhľadať vhodné miesto na vloženie v stabilnom (amortizovanom) čase. Absencia potreby vyvažovania alebo preusporiadania štruktúry zároveň prispieva k vysokej výkonnosti pri veľkom počte vkladaní.

V prípade stromových štruktúr vykazuje 2-3 strom lepšie výsledky z hľadiska priemerného času vkladania v porovnaní s červeno-čiernym stromom. Je to spôsobené tým, že v 2-3 strome je vyhľadanie vhodného miesta na vloženie zvyčajne rýchlejšie a samotné vloženie si nie vždy vyžaduje vytvorenie nového uzla. V prípadoch, keď je možné kľúč vložiť do druhej pozície už existujúceho uzla, sa v tejto implementácii využíva už alokovaná pamäť, čím sa eliminuje potreba volania funkcie `malloc()` a znižuje sa celkový čas operácie.

Červeno-čierny strom, hoci má logaritmickú zložitosť, si vyžaduje nevyhnutnú kontrolu vyváženosti stromu po každom vložení, a v mnohých prípadoch aj vykonanie rotácií a zmenu farby uzlov. To túto operáciu komplikuje a spomaľuje v porovnaní s 2-3 stromom.

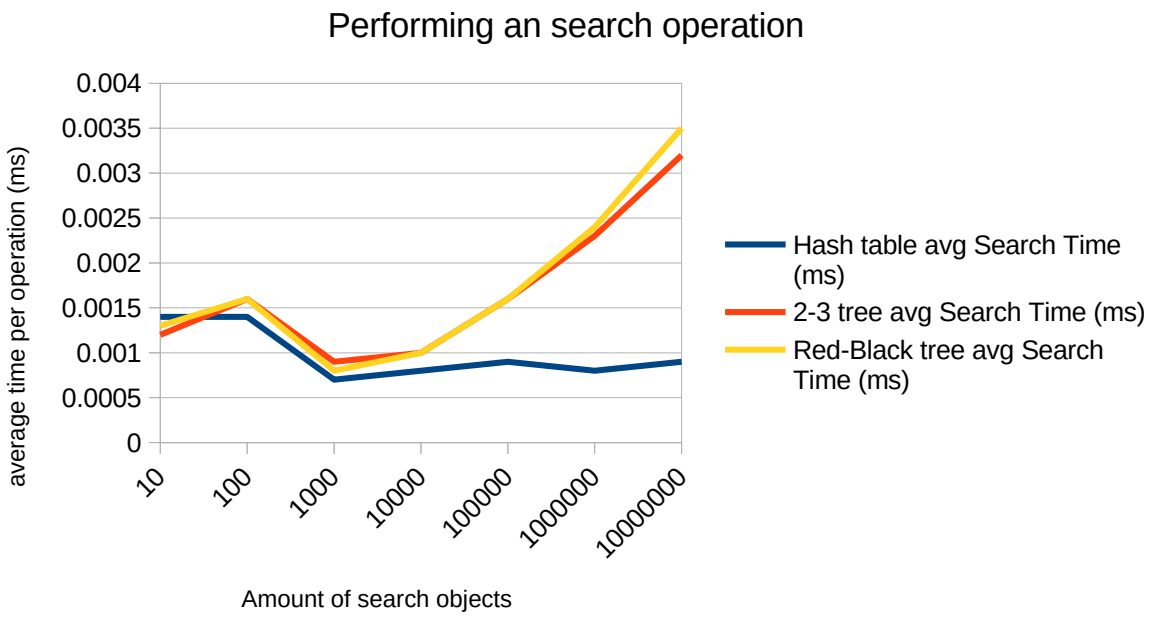
Pri malých objemoch údajov (do 100 operácií) sa pozorujú typické časové výkyvy. Tie sú, podobne ako v iných prípadoch, spôsobené vonkajšími faktormi, ako je cacheovanie, systémové procesy na pozadí, plánovanie operačného systému, ako aj nedostatočný počet iterácií na získanie stabilného priemeru.

Z analýzy teda vyplýva, že hašovacia tabuľka poskytuje najrýchlejšie vkladanie, 2-3 strom predstavuje optimálny kompromis medzi zložitosťou štruktúry a šetrením zdrojov, zatiaľ čo červeno-čierny strom zaostáva kvôli vyšším nákladom na vyvažovanie pri vkladaní.

2. Porovnanie rýchlosti vykonania operácie vyhľadávania.

number of searches	Hash table avg Search Time (ms)	2-3 tree avg Search Time (ms)	Red-Black tree avg Search Time (ms)
10	0.0014	0.0012	0.0013
100	0.0014	0.0016	0.0016
1000	0.0007	0.0009	0.0008
10000	0.0008	0.001	0.001
100000	0.0009	0.0016	0.0016
1000000	0.0008	0.0023	0.0024
10000000	0.0009	0.0032	0.0035

Karpenko Bohdan AIS ID: 135007



Ako vyplýva z výsledkov experimentu, najrýchlejšie vyhľadávanie poskytuje hašovacia tabuľka, čo je plne očakávané. Vďaka svojej povahe umožňuje hašovacia tabuľka prístup k prvku v stabilnom (amortizovanom) čase, nezávisle od veľkosti štruktúry. Vyhľadávanie prebieha na základe výpočtu hašovacej funkcie podľa kľúča, pričom nie je potrebná žiadna prehliadka stromu ani úprava jeho štruktúry.

V prípade 2-3 stromu a červeno-čierneho stromu sa čas vyhľadávania zväčšuje so zvyšujúcim sa počtom prvkov, čo zodpovedá ich logaritmickej zložitosti $O(\log n)$. V praxi to znamená, že so zväčšujúcou sa výškou stromu narastá aj počet vykonaných krokov. Napriek tomu však 2-3 strom v tomto teste prekonal červeno-čierny strom, čo môže byť spôsobené efektívnejšou navigáciou medzi uzlami a možnosťou vykonať rozhodnutia priamo v rámci jedného uzla s viacerými kľúčmi.

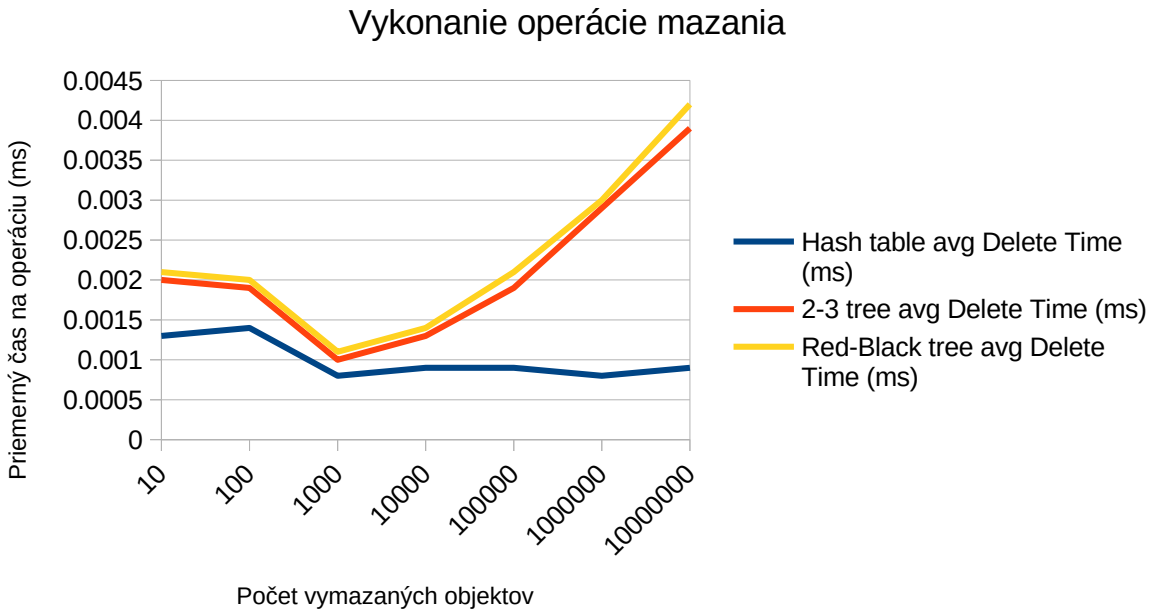
Naopak, červeno-čierny strom vykazuje o niečo pomalšie vyhľadávanie, čo môže byť dôsledkom prísne definovanej štruktúry s jedným kľúčom na uzol a potreby vykonávať viacero kontrol v hlbšej štruktúre.

Pri menších objemoch operácií (do 100) sa objavujú bežné výkyvy v čase vykonania, ktoré sú, ako aj v iných prípadoch, spôsobené cacheovaním, systémovou záťažou a nedostatočným počtom opakovaní na získanie spoľahlivého priemeru.

Na záver možno konštatovať, že hašovacia tabuľka zostáva najefektívnejším riešením pre operáciu vyhľadávania, zatiaľ čo medzi stromovými štruktúrami 2-3 strom preukázal vyššiu rýchlosť ako červeno-čierny strom, čím potvrdil svoju vhodnosť pre dynamické prostredia so zvýšeným dopytom na rýchly prístup k údajom.

3. Porovnanie rýchlosti vykonania operácie mazania.

Počet vymazaní	Priemerný čas mazania – hašovacia tabuľka (ms)	Priemerný čas mazania – – 2-3 strom (ms)	Priemerný čas mazania – červeno-čierny strom (ms)
10	0.0013	0.0020	0.0021
100	0.0014	0.0019	0.0020
1000	0.0008	0.0010	0.0011
10000	0.0009	0.0013	0.0014
100000	0.0009	0.0019	0.0021
1000000	0.0008	0.0029	0.0030
10000000	0.0009	0.0039	0.0042



Ako ukazujú výsledky experimentu, najnižší priemerný čas mazania dosahuje hašovacia tabuľka. Vďaka priamemu prístupu k prvkom na základe kľúča sa operácia mazania vykonáva bez potreby prechodu štruktúrou alebo jej preusporiadania. Samotná operácia spočíva v označení alebo vyčistení príslušnej pamäťovej bunky, čo zaberá stabilný a minimálny čas, aj pri veľkom počte prvkov.

V prípade stromových štruktúr – 2-3 stromu aj červeno-čierneho stromu – je priemerný čas mazania vyšší. Je to spôsobené zložitosťou operácií potrebných na zachovanie vyváženosti po odstránení prvku. Obe štruktúry vyžadujú dodatočné kontroly a úpravy, ako sú rotácie (pri červeno-čiernom strome) alebo zlučovanie uzlov (pri 2-3 strome), čo výrazne predlžuje čas operácie.

Červeno-čierny strom sa v tomto ohľade ukázal ako najpomalší. Dôvodom sú prísnejšie pravidlá vyvažovania – nutnosť zohľadniť farbu uzlov a vykonávať dodatočné rotácie, ktoré sa často spúšťajú práve po odstránení prvku. Naopak, 2-3 strom dokáže v niektorých prípadoch tieto náročné operácie obísť, najmä ak sa mazanie týka uzla s dvoma kľúčmi – vtedy môže byť prerozdelenie alebo zlúčenie zbytočné, čo vedie k úspore času.

V počiatočných fázach (do 100 operácií) sa pozorujú obvyklé výkyvy výsledkov, spôsobené vonkajšími faktormi: cacheovaním, systémovými volaniami, paralelnými procesmi a nedostatočnou veľkosťou vzorky pre spoľahlivé spriemerovanie.

Celkovo výsledky potvrdzujú, že mazanie v hašovacej tabuľke je najefektívnejšie, zatiaľ čo stromové štruktúry – hoci zachovávajú svoju vnútornú vyváženosť – vyžadujú ďalšie kroky, ktoré zvyšujú priemerný čas vykonania tejto operácie.

Karpenko Bohdan AIS ID: 135007

Zhrnutie

Na základe vykonanej analýzy možno vyvodiť závery týkajúce sa vhodnosti použitia rôznych dátových štruktúr v závislosti od konkrétnych požiadaviek:

- **Hašovacia tabuľka** sa ukázala ako najefektívnejšia z hľadiska rýchlosti vykonávania všetkých základných operácií (vkladanie, vyhľadávanie, mazanie), najmä pri veľkých objemoch údajov. Vďaka tomu je optimálnou voľbou pre úlohy, kde je kľúčovým rýchly prístup na základe jedinečného kľúča (napr. cacheovanie, slovníky, implementácia asociačných polí). Je však potrebné zohľadniť jej vysokú spotrebu pamäte, čo môže byť kritické v prostrediach s obmedzenými zdrojmi.
- **2-3 strom** predstavuje dobrý kompromis medzi výkonnosťou a stabilitou, a zároveň vykazuje primeranú pamäťovú náročnosť. Vďaka špecifikám implementácie, kde niektoré vloženia nevyžadujú vytvorenie nových uzlov, môže byť efektívnym riešením v systémoch s vysokou frekvenciou zmien a vkladania, ako sú databázy alebo súborové systémy. Jeho výkonnosť však klesá pri veľkých objemoch údajov v dôsledku predlžujúceho sa času vyhľadávania.
- **Červeno-čierny strom** preukázal najvyššiu pamäťovú efektivitu spomedzi testovaných štruktúr, čo z neho robí vhodnú voľbu v prípadoch, keď je dôležité uchovávať veľké množstvo usporiadaných údajov pri obmedzenej pamäti (napr. v kompilátoroch, indexovaní alebo pri implementácii vyvážených množín). Všetky operácie majú logaritmickú zložitosť, čo zabezpečuje stabilnú výkonnosť, avšak vysoká náročnosť operácie mazania môže byť nevýhodou v prostrediach s častými modifikáciami.

Z uvedeného vyplýva, že výber dátovej štruktúry by mal vychádzať z konkrétnych potrieb: požadovanej rýchlosti prístupu, obmedzení pamäte, frekvencie zmien a potreby zachovania usporiadania, pretože každá štruktúra má svoje silné a slabé stránky v závislosti od kontextu použitia.